

# Wirksamkeitsanalyse von Hochschulsupport und Prognose des Studienverlaufs

Abschlussprojekt im Kurs: *Deep Learning*  
bei **Dr. Bernd Ebenhoch**

Wilfried Keller

alfatraining Bildungszentrum

31.07.2026

- **Der Auslöser:** Vorher habe ich selbst (im Team) an der HSKL einen hybriden Mathe-Support entwickelt und mich gefragt: *Was genau bringt das? Und wie würde ich die Wirkung datengetrieben prüfen?*
- **DE:** Erste Konzeption von Datenstrukturen (ER-Modelle) und Simulation per SQL.
- **DA:** Aufbau einer dynamisch-stochastischen Python-Simulation.
  - Untersuchung mittels *Survival-Analyse* und *Cox-Regression*.
  - Visualisierung in Dashboards.
- **Deep Learning (Aktuelles Projekt):** Erweiterung der Thematik um Techniken des Maschinellen und Deep Learnings: *Was wird besser?*


# Exkurs: Grundlagen der Survival-Analyse

## Warum nicht einfach logistische Regression?

- **Zensierung:** Wir wissen oft nur: „Bis Semester X noch kein Abbruch“.
- **Zeitkomponente:** Es geht nicht nur darum *ob*, sondern *wann* Dropout eintritt.

## Zentrale Begriffe

- **Survival-Funktion  $S(t)$ :** Überlebenswahrscheinlichkeit bis Zeit  $t$  (z.B. Kaplan-Meier).
- **Hazard-Rate  $h(t)$ :** Momentanes Risiko zum Zeitpunkt  $t$ .
- **Hazard Ratio (HR):** Relatives Risiko.  $HR < 1$  bedeutet *Risikosenkung (positiv)*.





# Selektionsbias und Störfaktoren


Eine naive Analyse der Daten zeigt: Studierende, die Support nutzen, haben einen schlechteren Notenschnitt und eine längere Studiendauer als Studierende, die keinen Support nutzen.

*Schadet Support sogar?*

- **Das Dropout-Paradoxon:** Studierende, die Supportangebote intensiv nutzen, haben in unkontrollierten, statischen Modellen oft ein *höheres* Dropout-Risiko.
- **Die Ursache: (time-varying) Confounding:**
  - Supportnutzung ist selektiv: Schwächere Studierende brauchen mehr Support
  - Supportnutzung wird oft reaktiv ausgelöst (z.B. nach einer schlechten Note, insbesondere nach einem Fehlversuch).
  - Die schlechte Note ist ein Indikator für ein bereits erhöhtes Risiko.


# Statischer vs. Dynamischer Confounder

## 1. Statisches Setup



- HZB-Note war der primäre (statische) Störfaktor.
- Leicht durch einfache Cox-Regression mit Kontrollvariablen zu kontrollieren.

## 2. Dynamisches Setup



- **Das Problem:** Fehlversuche sind ein zeitveränderlicher Confounder.
- Frust triggert Support-Nutzung und verschlechtert gleichzeitig Folgeleistungen.

### Konsequenz (Vorgriff):

*Statisches Modell:*  $HR > 1.0$  (Support schadet scheinbar)  $\rightarrow$

*Dynamisches Modell:*  $HR \approx 0.37$  (sehr deutlicher „Effekt“)

# Die Lösung: Deep Survival Analysis

## Ansatz: Längsschnitt-Modelle & Neuronale Netze

- **DeepSurv & Extended Cox:** Daten im Panel-Format → zeitveränderliche Kovariaten in jedem Semester-Schritt modellierbar.
- **Recurrent & Transformer Survival:**
  - Inspiriert von DeepSurv++ / DeepHit: LSTM-/GRU- und Transformer-Architekturen kodieren die gesamte Historie in dynamische *Hidden States*.
  - *Achtung:* Exzellent in der Prognose, aber für isolierte kausale HR-Schätzung aufgrund mangelnder Generalisierung problematisch.
- **Ergebnis (Isolierung des Effekts):**
  - Kontrolle vergangener Fehlversuche lässt die scheinbar negative Korrelation verschwinden.
  - In geeigneten Panel-Modellen wird der isolierte *positive* Effekt messbar.

# Methodenvergleich: Survival-Modelle (Wirkung)

| Modell            | Datenstruktur     | Confounder-Kontrolle         | Hazard Ratio (Support)                              |
|-------------------|-------------------|------------------------------|-----------------------------------------------------|
| Landmark Cox      | 2D Snapshot       | Statisch                     | $HR > 1$ (Verzerrt: Selektionsbias)                 |
| DeepSurv          | 2D Snapshot       | Statisch (Non-linear)        | $HR > 1$ (Verzerrt: Selektionsbias)                 |
| Extended Cox      | Panel (Zeitreihe) | Dynamisch (Zeitveränderlich) | $HR \approx 0.37$ (Entstörter Effekt)               |
| Extended DeepSurv | Panel (Zeitreihe) | Dynamisch (Non-linear)       | $HR \approx 0.88$ (Via kontrafaktischer Simulation) |

## Zwischenfazit:

- Um „Kausalität“ und echte Hazard Ratios (HR) zu messen, sind interpretierbare Panel-Modelle (Extended Cox) unerlässlich.
- Die komplexeren rekurrenten Modelle eignen sich für diese spezifische HR-Analyse *nicht*; auf Prognose ausgelegte Modelle naiv für kontrafaktisch Vorhersage zu verwenden scheiterte im Kurztest dramatisch ( $HR > 1,5$ )



# Prognose & Früherkennung (Operativer Einsatz)

*Perspektivenwechsel: Für ein operatives Frühwarnsystem brauchen wir keine Kausalität – nur exzellente Prognosen. Welches Modell wäre geeignet?*

| Aufgabe        | Modell                      | Metriken             | Erkenntnis                                               |
|----------------|-----------------------------|----------------------|----------------------------------------------------------|
| Regression     | Keras MLP (Baseline)        | $R^2 \approx 0.89$   | Target-Leakage behoben.                                  |
| Regression     | LSTM (Semester)             | $R^2 \approx 0.93$   | <b>Trotzdem hohe Werte:</b> Simulations-Artefakt         |
| Regression     | GRU (Prüfung)               | $R^2 \approx 0.92$   | (CP/Fehlversuche sind wohl ein guter Notenproxy)         |
| Klassifikation | DeepHit                     | ROC: 0.83   PR: 0.28 | Multi-Task Modellierung funktioniert sehr gut.           |
| Klassifikation | Transformer (causal masked) | ROC: 0.82   PR: 0.29 | Attention ist stark (Baserate 2-5% → <b>~10x Lift!</b> ) |
| Klassifikation | GRU (Prüfung)               | ROC: 0.90   PR: 0.25 | Erkennt Dropout-Muster (Fails, CP-Verlauf) präzise.      |

- **Fazit:** Ein  $R^2 > 0.90$  ist hier *auch* als **Simulations-Artefakt** zu sehen: CP, Fails und Note entstehen aus derselben latenten „Fähigkeit“.
- In echten Daten wäre das Rauschen bei der Regression deutlich höher, während die **Klassifikation zur Frühwarnung robuster** bleibt.

- **Die Methodik ist entscheidend:**

- Naive statische Analysen führen zu falschen Schlüssen.
- Komplexe Bildungsverläufe erfordern longitudinale Datenstrukturen.

- **Trade-Off zwischen Modellen:**

- *Extended Cox* für validen Wirkungsnachweis und Erklärbarkeit.
- *Deep Sequence Models* als starke Engine für operative Frühwarnsysteme.

- **Neuronale Netze sind keine Magie:**

- PH-Annahmen & Linearität werden aufgegeben – bezahlt mit schlechter Extrapolation auf ungesehene Muster.
- *Eigene Versuche*: Kontrafaktischer Dauer-Support  $\Rightarrow$   $HR > 1,5$  – Generalisierung scheitert.

## Kausale Inference & Kontrafaktische Modelle

- **Echte Kausalität** geht aus den Beobachtungsdaten nicht abschließend hervor (ungemessene Faktoren bleiben).
- **PyTorch / PyCox Refactor:**
  - Evaluierung von Modellen mit explizitem Treatment-Effekt-Kopf, die ITE unter Ignorability-Annahme direkt schätzen.
  - Marginal Structural Models für kontrafaktische Modellierung adaptieren.
- **Beziehung zu rekurrenten Modellen ausbauen:**
  - Wie können wir die gute Prädiktionskraft der Transformer/GRUs nutzen, ohne bei kontrafaktischen Was-wäre-wenn-Szenarien an der schlechten Generalisierung zu scheitern?